

第 20 卷

自主实现：从数据契约到可发布结果

完成一条可测试、可断点续跑、可审计的梯度流核子胶子 TMD-PDF 生产流水线。

Tbl 20.00 5 个学习单元，固定编号不随合订方式改变

第 20 卷路线图

编号	学习单元
20.01	物理对象到数组与元数据契约
20.02	六阶段流水线与断点续跑
20.03	分层测试：代数、几何、统计与物理闭合
20.04	并行、I/O、性能与可复现运行
20.05	结课项目：生产判据与发布审计

来源：REPORT-TMD；PYQCD-TMD；PYQCD-PIPELINE；P40；P41；P44；P45

先修诊断与本卷出口

开始前应能回答

- ▶ V01-V19 全部核心能力

学完后应能独立完成

- ▶ 能设计模块化端到端实现
- ▶ 能用合成与真实数据分级验证
- ▶ 能明确判断何时结果仍只是原型

若先修项答不出，回到相应前卷；不要以术语熟悉代替可计算能力。

定量图：强标度的理想与通信受限示意




Fig 20.00: 解析性能模型，不代表 PyQCD 实测；生产优化前须 profile。

来源：Amdahl 定律

物理对象到数组与元数据契约：问题与图像

本节问题

怎样让公式中的每个指标在磁盘和内存里都有唯一、可检查的含义？




Fig 20.01: 概念关系示意；颜色只辅助分层。

物理原则

K 20.01 实现可分块或稀疏存储，但逻辑命名维度不能因性能布局而丢失。

来源：PYQCD-INFRA；PYQCD-PIPELINE；REPORT-TMD

物理对象到数组与元数据契约：定义与主公式

术语	本课程中的精确定义
Def 20.01-d8d7fd6c97 数据契约	规定字段、轴、dtype、单位、约定和不变量的协议
Def 20.01-deb31ef2e1 命名维度	以语义名称而非位置猜测数组轴
Def 20.01-17c92d8d6a 溯源	从最终点追到输入构型、代码和参数的记录链

Eq 20.01 主公式

$$\text{shape}(O) = (N_{\text{cfg}}, N_{\tau}, N_P, N_z, N_b, N_{\ell}, N_{t_{\text{ins}}}, N_{\text{proj}})$$

构型轴必须保留到真空扣除与重采样完成；其余轴对应明确物理调节量。

物理对象到数组与元数据契约：推导与证据边界

Der 20.01 由本节定义与前置结论逐步推出 Eq 20.01:

1. 从 $O(\text{cfg}, \tau, P, z, b, \ell, \text{tins}, \text{proj})$ 的自由标签逐一建立逻辑轴。
2. 笛卡尔数据元素数是各轴长度乘积；分块只改变布局。
3. 把 $\text{target}=\text{flg}[-,-]$ 、 spin_average 、 a 、单位、方向、 $2E/\text{projector}$ 、 $\text{Fourier}/\gamma$ /生成元约定和路径签名附为不可变元数据。

可执行检查

SYM 20.01 命名轴笛卡尔积的元素数；1/1 项通过；SymPy exact。
假设：所有逻辑轴长度为正整数

适用边界：分块、压缩和稀疏布局只改变物理存储，不改变逻辑契约。

物理对象到数组与元数据契约：计算算法

Alg 20.01

1. 为每阶段定义输入/输出 dataclass 或 JSON schema。
2. 加载时验证轴名、长度、dtype、有限值、单位和版本。
3. 拒绝隐式 broadcasting、缺失 bT、空 staple 与无构型轴的生产输入。
4. 写 manifest，含输入校验和、代码状态、命令、随机种子和上游产物 ID。

停止条件与交叉检查

- ✓ 任意切片后剩余轴名必须同步更新。
- ✓ 相同数值但不同单位/路径哈希的数据不得自动合并。

代码映射

```
../PyQCD/pyqcd/tools/_io.py、 pipeline/_  
config.py、 _validate.py
```


物理对象到数组与元数据契约：练习与完整解答

Ex 20.01

Ncfg=100，其余七轴长度均为 2，逻辑元素数是多少？

Sol 20.01

$100 \times 2^7 = 12,800$ ；复数 128 位裸存储约 204,800 字节。

回看：[Def 20.01-d8d7fd6c97](#)；[Eq 20.01](#)；[SYM 20.01](#)；[Alg 20.01](#)。

来源：PYQCD-INFRA；PYQCD-PIPELINE；REPORT-TMD

六阶段流水线与断点续跑：问题与图像

本节问题

如何把一天到数月的计算拆成失败可恢复、结果不漂移的阶段？




Fig 20.02: 概念关系示意；颜色只辅助分层。

物理原则

K 20.02 哈希保证可识别性而非物理正确；每阶段仍需不变量和统计质量门。

来源：PYQCD-PIPELINE；PYQCD-INFRA

六阶段流水线与断点续跑：定义与主公式

术语	本课程中的精确定义
Def 20.02-d453c01332 有向无环图	按产物依赖组织且无循环的任务图
Def 20.02-822e551ad3 幂等	相同输入重复运行产生相同可识别输出
Def 20.02-9c63b8df4c checkpoint	完成阶段的原子状态和产物记录

Eq 20.02 主公式

$$H_{\text{out}} = \text{SHA256}(H_{\text{inputs}}, H_{\text{config}}, H_{\text{code}}, \text{stage})$$

内容寻址 ID 由输入、配置、代码状态和阶段共同决定。

六阶段流水线与断点续跑：推导与证据边界

Der 20.02 由本节定义与前置结论逐步推出 Eq 20.02:

1. 把决定性字段按固定顺序规范化编码。
2. SHA256 对同一字节串给同一摘要，任一输入变化通常改变摘要。
3. 将输出 ID 与完成标记原子写入；下游只接受全部依赖 ID 匹配的产物。

可执行检查

SYM 20.02 内容寻址依赖的符号结构；2/2 项通过；SymPy exact。

假设：把 SHA256 视为四元输入的确定性构造函数

适用边界：碰撞抗性是密码学性质，不由 SymPy 证明；实际实现还需规范化字节编码和原子写入。

六阶段流水线与断点续跑：计算算法

Alg 20.02

1. 划分 flow、operator、correlator、disc-fit、renorm-soft、extract-limits 六阶段。
2. 每阶段启动前验证依赖、资源估计和输出目录不冲突。
3. 先写临时分块，校验后原子重命名并写完成清单。
4. 重启时只跳过 ID、schema、校验和与质量门全部一致的阶段。

停止条件与交叉检查

- ✓ 相同输入应产生相同 stage ID。
- ✓ 只改 soft 几何时，flow 可复用而 renorm-soft 及下游必须失效。

代码映射

```
../PyQCD/pyqcd/pipeline/_runner.py、_steps.py、  
_tmd9.py
```

六阶段流水线与断点续跑：练习与完整解答

Ex 20.02

配置改变 Pz 列表，哪些阶段至少必须重跑？

Sol 20.02

核子 correlator/断连拟合及下游必须重跑；只依赖规范链接的 flow 可复用。

回看： [Def 20.02-d453c01332](#)； [Eq 20.02](#)； [SYM 20.02](#)； [Alg 20.02](#)。

来源：PYQCD-PIPELINE；PYQCD-INFRA

本节问题

在昂贵真实系综运行前，哪些错误必须在小测试中被截住？




Fig 20.03: 概念关系示意；颜色只辅助分层。

物理原则

K 20.03 单次 $|\text{pull}| < 2$ 不是证明；需随机重复、故障注入和真实数据不变量共同建立证据。

来源：PYQCD-TMD-VALIDATION；PYQCD-STATISTICS；MYQCD-FORMULAS

分层测试：代数、几何、统计与物理闭合：定义与主公式

术语	本课程中的精确定义
Def 20.03-f1ae34ca85 property test	对一类随机输入检查不变量
Def 20.03-d48705fcfb 合成注入	从已知真值生成数据并检验能否回收
Def 20.03-539b3cfda0 闭合测试	正向生成与逆向提取组合后回到目标

Eq 20.03 主公式

$$\delta_{\text{closure}} = \frac{\hat{\theta} - \theta_{\text{true}}}{\sigma_{\hat{\theta}}}, \quad |\delta_{\text{closure}}| \lesssim 2 \quad (\text{单次诊断})$$

pull 用估计误差归一化偏差；重复实验应检验均值、宽度与覆盖率。

分层测试：代数、几何、统计与物理闭合：推导与证据边界

Der 20.03 由本节定义与前置结论逐步推出 Eq 20.03:

1. 若估计无偏且 σ 校准, pull 近似标准正态。
2. 标准正态约 95.45% 落在 $[-2, 2]$ 。
3. 单次超界提示问题; 长期覆盖率才判断误差估计是否可靠。

可执行检查

SYM 20.03 标准正态两倍标准差覆盖率; 2/2 项通过; SymPy exact。

假设: pull 服从标准正态的理想校准模型

适用边界: 真实覆盖率必须由重复合成实验测量, 单次 $|\text{pull}| < 2$ 不证明正确。

分层测试：代数、几何、统计与物理闭合：计算算法

Alg 20.03

1. 代数层测试 $SU(3)$ 、 γ 代数、Fourier 归一化和 SymPy 公式。
2. 几何层测试端点、反向、规范不变和非零 bT 守卫。
3. 统计层注入多态、协方差、soft、匹配与四极限，检验偏差/覆盖。
4. 小真实系综只验证链路；生产声明需完整统计、多尺度和外部交叉检查。

停止条件与交叉检查

- ✓ 输入乘共同 UV 因子后 ZR 比值应不变。
- ✓ 打乱构型配对应使断连信号消失。

代码映射

本课程 `sympy_validation.py`; PyQCD TMD
`validation` 参考

Ex 20.03

1000 次覆盖实验中 950 个 95% 区间含真值，经验覆盖率是多少？

Sol 20.03

95%；二项标准误约 $\sqrt{0.95 \times 0.05/1000}=0.69\%$ 。

回看： [Def 20.03-f1ae34ca85](#)； [Eq 20.03](#)； [SYM 20.03](#)； [Alg 20.03](#)。

来源：PYQCD-TMD-VALIDATION；PYQCD-STATISTICS；MYQCD-FORMULAS

并行、I/O、性能与可复现运行：问题与图像

本节问题

如何扩展到许多构型和几何点，同时不牺牲确定性与数据完整性？




Fig 20.04: 概念关系示意；颜色只辅助分层。

物理原则

K 20.04 先测量真实瓶颈；GPU/MPI 接口存在不等于当前路径已获加速或数值一致。

来源：PYQCD-INFRA；PYQCD-PIPELINE

并行、I/O、性能与可复现运行：定义与主公式

术语	本课程中的精确定义
Def 20.04-e43bf33539 数据并行	不同进程处理独立构型或参数块
Def 20.04-0a008ea643 collective I/O	进程协同写入全局数据集
Def 20.04-3316d23eab 强标度	固定总问题规模增加资源的加速行为

Eq 20.04 主公式

$$S(p) = \frac{1}{f + (1 - f)/p}$$

Amdahl 定律说明串行比例 f 给强标度加速设置上限 $1/f$ 。

并行、I/O、性能与可复现运行：推导与证据边界

Der 20.04 由本节定义与前置结论逐步推出 Eq 20.04:

1. 把串行时间归一为 f ，并行部分为 $1-f$ 。
2. p 个理想进程把并行时间缩为 $(1-f)/p$ 。
3. 总相对时间为 $f+(1-f)/p$ ，取倒数得到加速比。

可执行检查

SYM 20.04 Amdahl 强标度；3/3 项通过；SymPy exact。

假设： $0 < f \leq 1$ ；并行部分理想均分且忽略额外通信开销

适用边界：真实性能必须 **profile**；模型不是 PyQCD 实测。

并行、I/O、性能与可复现运行：计算算法

Alg 20.04

1. 优先按构型分配，以保持配置级统计独立和少通信。
2. 对路径前缀、flow checkpoints 和 Fourier 核做只读缓存。
3. 每 rank 写独立临时分块或经验证 collective I/O，禁止无锁追加。
4. 记录 wall time、内存、I/O、通信、硬件和确定性归约。

停止条件与交叉检查

- ✓ $p=1$ 时 $S=1$ 。
- ✓ $p \rightarrow \infty$ 时 $S \rightarrow 1/f$; $f=0$ 才有理想无限线性标度。

代码映射

```
../PyQCD/pyqcd/parallel/_mpi.py、_mpi_  
transport.py; tools/_io.py
```

并行、I/O、性能与可复现运行：练习与完整解答

Ex 20.04

$f=0.05$ 、 $p=16$ 时理论加速比是多少？

Sol 20.04

$1/[0.05+0.95/16] \approx 9.14$ ，明显小于理想 16。

回看：[Def 20.04-e43bf33539](#)；[Eq 20.04](#)；[SYM 20.04](#)；[Alg 20.04](#)。

来源：PYQCD-INFRA；PYQCD-PIPELINE

本节问题

什么时候可以把图称为“梯度流方案的核子胶子 TMD-PDF”，而不是演示曲线？




Fig 20.05：概念关系示意；颜色只辅助分层。

物理原则

K 20.05 极限只在 CT 已消去 finite-staple 的非解析流时结构、且数据覆盖支持时有意义；每个方向都要有误差与停止门。

来源：REPORT-TMD；P40；P41；P44；P45；PYQCD-TMD

结课项目：生产判据与发布审计：定义与主公式

术语	本课程中的精确定义
Def 20.05-e7fe51c115 证据状态	接口存在、测试通过、方案闭合、真实数据验证的分级
Def 20.05-d7d8280e5b 发布审计	对物理定义、数据、代码、统计和声明逐项核查
Def 20.05-78246921e1 降级措辞	关键环节缺失时准确描述原型/演示

Eq 20.05 主公式

$$\begin{aligned} \mathcal{P}_1^{[-,-]} = & \lim_{\substack{a \rightarrow 0, \, P_z \rightarrow \infty \\ \tau \rightarrow 0, \, \ell \rightarrow \infty}} \left[C_{g\Sigma}^{-1} \otimes \mathcal{U}_{CS} \mathcal{F}_z \right. \\ & \left. \times C_{\Gamma, \text{flow} \rightarrow S} \mathcal{R}_{\text{qsoft}, UV}^S \frac{2E_P}{\mathcal{K}_{\Pi}} R_{3\text{pt}/2\text{pt}}^{B, \Pi} \right] \end{aligned}$$

最终主对象是自旋平均 $[-,-]$ 通道的测量、运动学归一化、quasi-soft/UV/流方案转换、Fourier、CS、胶子-singlet 匹配和四类极限的受控组合。

结课项目：生产判据与发布审计：推导与证据边界

Der 20.05 由本节定义与前置结论逐步推出 Eq 20.05:

1. $R_{3pt}/2ptB$ 来自真实核子二点与 flowed 非零 bT 、past-pointing finite-staple 胶子断连三点； $2E/KII$ 恢复目标矩阵元。
2. R_{qsoft}, UVS 使用方案兼容的 $v/vbar$ 、regulator 与 zero-bin； $CT, flow \rightarrow S$ 处理完整路径、端点、cusp 和 mixing。
3. F_z 、 UCS 、 $C_g \Sigma^{-1}$ 在共同 x/ν 与至少三个 P_z 上处理有限 z 、rapidity 演化和胶子—singlet 匹配；联合极限移除调节量。

可执行检查

SYM 20.05 四类调节量的联合理想极限；1/1 项通过；SymPy exact。

假设：使用可分离的领先修正代理； P_{ell} 为正

适用边界：真实极限含交叉项、对数、混合和相关数据；该检查只验证终章流程骨架。

结课项目：生产判据与发布审计：计算算法

Alg 20.05

1. 阶段 A：小格点合成数据通过公式、几何、统计、闭合和故障注入测试。
2. 阶段 B：真实多构型检查信号、对称性、流时窗、 $tsep$ 、 bT 、 ℓ 与多 P_z 。
3. 阶段 C：多格距、多 P_z 、多 τ 、多 ℓ 完成相关联合外推和误差预算。
4. 阶段 D：冻结配置/代码/环境，独立复算关键点，生成 manifest 与限制声明。

停止条件与交叉检查

- ✓ $bT=0$ 只能称裸几何退化/直线原型；物理 collinear 联系需 small- bT OPE。
- ✓ $soft=1$ 、缺 CT 、单构型扣除或无混合/多尺度外推时不得标为真实 TMD 验证。

代码映射

../PyQCD/examples/pyqcd/test9_gluon_tmd_nucleon.py 与 pipeline/_tmd9.py (实现入口；证据状态须另审计)

结课项目：生产判据与发布审计：练习与完整解答

Ex 20.05

给出最小但不可省略的“物理结果”输入维度。

Sol 20.05

至少需多构型；非零多个 bT ；多个 ℓ 、 z 、 $tsep$ 、 τ 、 a ；至少三个有效 P_z ；方案兼容且已定义 `regulator/zero-bin/`转换核的 `quasi-soft`；胶子与 `singlet` 匹配输入。点数由可辨识性和误差目标决定，不能用单点替代极限。

回看：[Def 20.05-e7fe51c115](#)；[Eq 20.05](#)；[SYM 20.05](#)；[Alg 20.05](#)。

来源：REPORT-TMD；P40；P41；P44；P45；PYQCD-TMD

第 20 卷能力清单

- ✓ 能设计模块化端到端实现
- ✓ 能用合成与真实数据分级验证
- ✓ 能明确判断何时结果仍只是原型

通过标准

不以“看懂”为标准：应能从空白纸推导主公式、实现算法、解释检查失败意味着什么，并完成本卷练习。

第 20 卷来源 (1/3)

ID	来源	本卷用途
Src REPORT-TMD	梯度流核子胶子 TMD 项目报告	本课程终点定义、实现现状、证据分级和关键物理边界。
Src PYQCD-TMD	PyQCD TMD 主链技能	六阶段 TMD 物理链和端到端接口。
Src PYQCD-PIPELINE	PyQCD 流水线技能	配置、守卫、元数据、断点续跑和产物清单。
Src P40	梯度流中的非光锥威尔逊线算符	论文图谱 P40 的完整原始 PDF；底稿 arXiv:2312.05032；SHA-256 31292da5c276c237...。
Src P41	首个核子胶子部分子分布	论文图谱 P41 的完整原始 PDF；底稿 arXiv:2505.13321；SHA-256 09eff6064b5d9c67...。

第 20 卷来源 (2/3)

ID	来源	本卷用途
Src P44	从准 TMD 波函数确定 CS 核	论文图谱 P44 的完整原始 PDF；底稿 arXiv:2204.00200；SHA-256 589d870d484889ae...。
Src P45	LaMET 计算 TMD 软函数	论文图谱 P45 的完整原始 PDF；底稿 arXiv:2005.14572；SHA-256 22b1f2cbca968f30...。
Src PYQCD-INFRA	PyQCD 基础设施技能	后端、I/O、MPI 和资源治理。
Src PYQCD-TMD-VALIDATION	PyQCD TMD 验证矩阵	合成闭合、故障注入和生产质量门。
Src PYQCD-STATISTICS	PyQCD 统计技能	自相关、重采样、协方差和拟合验证。

第 20 卷来源 (3/3)

ID	来源	本卷用途
Src FORMULAS	MYQCD- MyQCD 可执行公式注册表	复杂公式的 SymPy 精确代理与证据边界。